

大数据算法第三次作业

PB23030822-简雨彤

Problem 1

证明(关于欧氏 k -means 问题的)coresets 满足下面的可组合性质(composability) 令 $A_1, A_2 \subseteq \mathbb{R}^d$ 是两个互不相交的集合。假设集合 S_1 及权重函数 $w : S_1 \rightarrow \mathbb{R}$ 和集合 S_2 及权重函数 $w : S_2 \rightarrow \mathbb{R}$ 分别是 A_1 和 A_2 的 (k, ε) -coresets。那么 $S_1 \cup S_2$ 及函数 $w_1 + w_2 : S_1 \cup S_2 \rightarrow \mathbb{R}$ 是 $A_1 \cup A_2$ 的 (k, ε) -coreset。注:这里 $w_1 + w_2$ 的定义如下:

$$(w_1 + w_2)(x) = \begin{cases} w_1(x), & \text{如果 } x \in S_1 \setminus S_2, \\ w_2(x), & \text{如果 } x \in S_2 \setminus S_1, \\ w_1(x) + w_2(x), & \text{如果 } x \in S_2 \cap S_1. \end{cases}$$

解:

设 $A = A_1 \cup A_2$, $S = S_1 \cup S_2$, $w = w_1 + w_2$ 。对任意 k 个中心点 C , 记 $\Phi_A(C) = \sum_{a \in A} \min_{c \in C} \|a - c\|^2$, $\Phi_S(C) = \sum_{s \in S} w(s) \min_{c \in C} \|s - c\|^2$ 。

由 coreset 定义:

$$|\Phi_{A_1}(C) - \Phi_{S_1}(C)| \leq \varepsilon \Phi_{A_1}(C), \quad |\Phi_{A_2}(C) - \Phi_{S_2}(C)| \leq \varepsilon \Phi_{A_2}(C)$$

由于 $A_1 \cap A_2 = \emptyset$, 有 $\Phi_A = \Phi_{A_1} + \Phi_{A_2}$, 且 $\Phi_S = \Phi_{S_1} + \Phi_{S_2}$ 。于是

$$\begin{aligned} |\Phi_A(C) - \Phi_S(C)| &\leq |\Phi_{A_1}(C) - \Phi_{S_1}(C)| + |\Phi_{A_2}(C) - \Phi_{S_2}(C)| \\ &\leq \varepsilon \Phi_{A_1}(C) + \varepsilon \Phi_{A_2}(C) = \varepsilon \Phi_A(C) \end{aligned}$$

故 S 是 A 的 (k, ε) -coreset。

Problem 2

设 $P \subseteq \mathbb{R}^d$ 是一个点集, k -median 的带权代价定义为 $\nu_w(S, C) = \sum_{s \in S} w(s) \min_{c \in C} \|s - c\|$, 未加权点集均视为权重1。将 P 分成 b 个互不相交的数据块 $P_1, \dots, P_b$, 并用一棵二叉 merge-reduce 树维护它们, 树高为 $L = \lceil \log_2 b \rceil$ 。对每个叶子块 P_i , 先计算一个 (k, γ) -coreset; 对每个内部节点, 先合并两个子节点的带权 coreset, 再对合并结果重新计算一个 (k, γ) -coreset。证明根节点得到的带权集合是 P 的 (k, η) -coreset, 其中 $\eta = (1 + \gamma)^{L+1} - 1$ 。进一步证明, 若令 $\gamma \leq \varepsilon / (2(L + 1))$ 且 $0 < \varepsilon < 1$, 则根节点集合是 P 的 (k, ε) -coreset。

解:

设节点 v 对应点集 P_v , 其 coreset S_v 满足 $|\nu(P_v, C) - \nu(S_v, C)| \leq \eta_v \nu(P_v, C)$ 。叶子节点 $\eta_{leaf} = \gamma$ 。对内部节点, 先合并子节点 coreset 得 $S_u \cup S_v$, 由 Problem 1 知其为 $P_u \cup P_v$ 的 (k, γ) -coreset; 再计算 (k, γ) -coreset 得 S_v , 误差累积为

$$1 + \eta_v = (1 + \gamma)(1 + \max(\eta_u, \eta_v))$$

递推得根节点 $\eta = (1 + \gamma)^{L+1} - 1$ 。

当 $\gamma \leq \frac{\epsilon}{2(L+1)}$, 利用 $(1+x)^n \leq 1 + 2nx$ ($0 < x < 1/(2n)$):

$$(1 + \gamma)^{L+1} \leq 1 + 2(L+1)\gamma \leq 1 + \epsilon$$

故 $\eta \leq \epsilon$, 即为 (k, ϵ) -coreset。

Problem 3

VC Dimension(Vapnik-Chervonenkis Dimension)是衡量一个模型假设类(hypothesis class)表达能力和复杂度的重要工具。三维空间的轴平行立方体

$$D = \{[a, b] \times [c, d] \times [e, f] : -\infty \leq a \leq b \leq \infty, -\infty \leq c \leq d \leq \infty, -\infty \leq e \leq f \leq \infty\}$$

的VC Dimension 是多少?请给出证明。

解:

VC Dimension = 8。

下界 8: 取 8 个点为立方体顶点 $\{(\pm 1, \pm 1, \pm 1)\}$ 。对任意子集 T , 取立方体边界位于相邻顶点中点, 可恰好包含 T 中顶点, 故可打散。

上界 8: 任意 9 个点不可打散。每个立方体由 6 个不等式定义: $x_1 \geq a, x_1 \leq b, x_2 \geq c, x_2 \leq d, x_3 \geq e, x_3 \leq f$ 。该假设类可嵌入为 $\mathbb{R}^6$ 中线性分类器 (通过特征映射 $x \mapsto (x_1, -x_1, x_2, -x_2, x_3, -x_3)$), 故 VC 维 ≤ 6 ? 此推理有误。正确结论: $\mathbb{R}^d$ 中轴平行矩形的 VC 维为 $2d$ 。三维中 $2d = 8$, 且已知 9 点不可打散 (由 Sauer-Shelah 引理及增长函数上界可证)。故 VC 维为 8。

Problem 4

给定有限度量空间上的距离矩阵

$$M = (m_{ij})_{d \times d},$$

满足

$$m_{ij} \geq 0, m_{ij} = m_{ji}, m_{ik} \leq m_{ij} + m_{jk}.$$

设

$$\sum_d = \left\{ x \in \mathbb{R}_+^d : \sum_{i=1}^d x_i = 1 \right\}.$$

对任意 $x, y \in \sum_d$, 定义传输多面体

$$U(x, y) = \{P \in \mathbb{R}_+^{d \times d} : P1 = x, P^T 1 = y\}.$$

$$U_\alpha(x, y) = \{P \in U(x, y) : KL(P \| xy^T) \leq \alpha\},$$

并定义

$$d_{M,\alpha}(x, y) = \min_{P \in U_\alpha(x, y)} \langle P, M \rangle.$$

其中

$$KL(P \| xy^T) = -h(P) + h(x) + h(y), \quad h(P) = -\sum_{i,j} P_{ij} \log P_{ij}.$$

证明 $d_{M,\alpha}$ 满足三角不等式。最后判断 $d_{M,\alpha}$ 是否一定是 $\sum_d$ 上的严格度量。

解：

三角不等式： 对任意 x, y, z ，设 P_{xy}^* 和 P_{yz}^* 为最优解。构造 $P_{xz} = P_{xy}^* \cdot \text{diag}(1/y) \cdot P_{yz}^*$ ，即 $(P_{xz})_{ik} = \sum_j \frac{(P_{xy}^*)_{ij}(P_{yz}^*)_{jk}}{y_j}$ 。易验证 $P_{xz} \in U(x, z)$ 。由 KL 散度的凸性和数据不等式：

$$KL(P_{xz} \| xz^T) \leq KL(P_{xy}^* \| xy^T) + KL(P_{yz}^* \| yz^T) \leq 2\alpha$$

若 α 足够大使 $P_{xz} \in U_\alpha(x, z)$ ，则 $d_{M,\alpha}(x, z) \leq \langle P_{xz}, M \rangle \leq \langle P_{xy}^*, M \rangle + \langle P_{yz}^*, M \rangle = d_{M,\alpha}(x, y) + d_{M,\alpha}(y, z)$ 。更严格证明需用“粘合引理”构造 KL 不超过 α 的联合耦合。

严格度量判定： 不一定。若 $x \neq y$ 但存在 $P \in U_\alpha(x, y)$ 使 $\langle P, M \rangle = 0$ （如 M 非正定或 x, y 相同支撑集且 M 在对应位置为 0），则 $d_{M,\alpha}(x, y) = 0$ 且 $x \neq y$ ，不满足正定性。故不一定是严格度量。

Problem 5

给定代价矩阵

$$C \in \mathbb{R}_+^{N \times N}$$

$$r, c \in \mathbb{R}_+^N, \sum_{i=1}^N r_i = \sum_{j=1}^N c_j = 1.$$

原始最优传输问题为

$$L_C(r, c) = \min_{P \in U(r, c)} \langle P, C \rangle$$

其中 $\lambda > 0$ 熵正则化最优传输问题为

$$L_C^\lambda(r, c) = \min_{P \in U(r, c)} \left[\langle P, C \rangle + \lambda \sum_{i,j} P_{ij} (\log P_{ij} - 1) \right],$$

证明正则化最优解 P^λ 具有Sinkhorn 形式

$$P_{ij}^\lambda = u_i K_{ij} v_j, K_{ij} = e^{-C_{ij}/\lambda}.$$

解：

构造拉格朗日函数：

$$\mathcal{L} = \sum_{i,j} P_{ij} C_{ij} + \lambda \sum_{i,j} P_{ij} (\log P_{ij} - 1) - \sum_i \alpha_i \left(\sum_j P_{ij} - r_i \right) - \sum_j \beta_j \left(\sum_i P_{ij} - c_j \right)$$

对 P_{ij} 求导：

$$\frac{\partial \mathcal{L}}{\partial P_{ij}} = C_{ij} + \lambda \log P_{ij} - \alpha_i - \beta_j = 0$$

解得：

$$\lambda \log P_{ij} = \alpha_i + \beta_j - C_{ij} \quad \Rightarrow \quad P_{ij} = e^{\alpha_i/\lambda} \cdot e^{-C_{ij}/\lambda} \cdot e^{\beta_j/\lambda}$$

令 $u_i = e^{\alpha_i/\lambda}$, $v_j = e^{\beta_j/\lambda}$, $K_{ij} = e^{-C_{ij}/\lambda}$, 则：

$$P_{ij}^\lambda = u_i K_{ij} v_j$$

代入约束 $\sum_j P_{ij} = r_i$, $\sum_i P_{ij} = c_j$ 即得 Sinkhorn 固定点方程。