

论文阅读报告

论文题目： Comparing Specialised Small and General Large Language Models on Text Classification: 100 Labelled Samples to Achieve Break-Even Performance

会议： EMNLP 2025 Main Conference

姓名： 简雨彤

学号： PB23030822

一、文章研究的问题

这篇文章研究了一个在实际应用中非常常见的问题：**一个经过微调的小型专用模型（比如BERT），需要多少标注样本，才能在文本分类任务上表现不低于那些不需要训练、直接通过提示词或上下文学习就能工作的大型通用模型（比如GPT-4、LLaMA）？**

因为在实际工作中，标注数据往往很贵、很难获取，所以这个问题显得很重要。而大型模型的API调用成本也不低。所以搞清楚“什么时候该用哪种方法”，可以帮助我们节省时间和金钱。

二、提出的方法

作者设计了一套系统的比较实验框架，核心思路是找到“**性能平衡点**”——即专用模型开始超过通用模型的那个标注样本数量。

具体做法：

- 选择了8个文本分类数据集**，涵盖二分类和多分类，任务类型包括情感分析、语法判断、问答、意图识别等，保证多样性。
- 对比了四种方法：**
 - 微调（Fine-tuning）：用BERT、RoBERTa。
 - 提示（Prompting）：零样本，直接给模型指令
 - 上下文学习。（In-context Learning）：给几个示例，让模型模仿。
 - 指令微调（Instruction Tuning）：先微调模型，再通过提示使用。
- 考虑了性能方差：**每次实验重复多次（微调100次，其他20次），用均值和标准差来反映模型对随机因素的敏感程度。

三、方法的优缺点

优点：

- 实验设计非常全面：**覆盖了8个数据集、8个模型、4种方法，而且考虑了随机性影响。
- 关注实际问题：**回答了一个非常实用的“多少标注样本够用”的问题，而不是只追求更高的准确率。
- 结论清晰可操作：**给出了具体的数字建议（平均100个样本），对从业者有直接指导意义。

缺点/局限性：

1. **只做了英文分类任务**：结论是否能推广到生成任务（如翻译、摘要）或其他语言，还需要验证。
2. **计算成本高，评估受限**：大型模型只评估了1000个测试样本的子集，可能带来偏差。
3. **提示词未完全优化**：对所有模型用了同一套提示模板，但不同模型对提示词的敏感度不同，可能影响了某些模型的表现。
4. **存在潜在数据泄漏**：不知道实验用的数据集是否在大型模型的预训练中出现过，如果是，大型模型的优势可能被高估。

四、实验结果与分析

核心发现：

1. **专用模型不需要很多标注样本**：平均只需要100个标注样本，微调后的小模型就能在性能上超过不训练的大模型。有些数据集甚至只需要10-50个样本。
2. **二分类任务更难**：在情感分析、语法判断等二分类任务上，需要的样本量远多于多分类任务（最多需要几千甚至上万个）。
3. **性能方差影响很大**：考虑方差后，所需的标注样本数量平均增加了100%-200%。也就是说，如果只跑少量实验，可能会误判哪个模型更好。
4. **更大的模型不一定更好**：在提示和上下文学习中，小型模型（Flan-T5）有时反而比LLaMA、GPT表现更好或方差更低。

我认为这个结果其实挺反直觉的。我们总以为GPT-4这种大模型无所不能，但在分类这种结构化任务上，一个几百兆的BERT微调一下就能打得有来有回，而且只需要几十上百条标注数据。这说明“模型大小”不是万能的，任务匹配和针对性训练更重要。

五、与本课程内容的关联

本课程《深度学习基础》主要讲解了神经网络的基本原理、常见模型结构（如卷积神经网络、循环神经网络、Transformer）以及模型训练中的关键技术（如反向传播、正则化、优化算法等）。这篇论文虽然不涉及新的网络结构或训练算法，但它研究的问题——**在有限标注数据下，如何选择和使用不同规模的深度学习模型**——与课程中强调的“模型选型与资源权衡”密切相关。

具体来说：

- 课程中讲到，深度学习模型的性能受数据量、模型容量、训练方式等多个因素影响。本文正是通过实验，量化了这些因素对文本分类任务的影响，给出了“小模型+适量微调”与“大模型+提示学习”之间的性能对比。
- 课程中提到的“过拟合”“欠拟合”现象，在本文中体现为：当标注样本极少时，微调的小模型性能不稳定（方差大）；而随着样本增加，模型逐渐稳定并超越大模型。
- 课程中介绍的Transformer架构，是本文所用所有模型（BERT、RoBERTa、Flan-T5、LLaMA、GPT等）的共同基础。本文可以看作是对同一类架构在不同规模、不同训练策略下的“工程对比”。

我认为，课程教会了我们深度学习模型“怎么搭、怎么训”，而这篇论文补充了一个重要视角：**在资源有限的实际场景中，应该怎么选、怎么权衡**。这对于从事深度学习相关的工作或研究的人来说，非常实用。

六、阅读收获与个人感受

收获：

1. 我以前一直以为大模型在几乎所有任务上都能碾压小模型，但这篇论文让我意识到：在分类这种“输出空间固定”的任务上，小模型通过针对性训练，可以用很少的数据追上大模型。这让我对“模型选型”有了更理性的认识。
2. “方差”这个点让我印象很深。我以前看论文只看平均准确率，忽略了不同跑之间的波动。这篇论文提醒我：一个模型如果时好时坏，那在实际部署中其实很危险。以后我自己做实验，也会注意报告标准差。

总体评价：

这是一篇非常扎实的工程型论文，没有特别复杂的数学推导，但实验设计严谨、结论清晰、对实际工作有指导意义。即使我第一次读EMNLP论文，我也觉得难度适中，能看懂大部分内容，学到了很多关于实验设计的细节。